

# Inspeção Automatizada de Qualidade em Produtos

1<sup>st</sup> João Victor Cardoso Lopes

*Centro de Informática*

*Universidade Federal de Pernambuco*

Recife, Brasil

jycl@cin.ufpe.br

2<sup>nd</sup> Marco Antônio Vasconcelos Freitas Filho

*Centro de Informática*

*Universidade Federal de Pernambuco*

Recife, Brasil

mavff@cin.ufpe.br

**Abstract**—Apresentamos uma proposta de projeto para a disciplina de Deep Learning do Centro de Informática (CIn) da Universidade Federal de Pernambuco (UFPE). Nosso objetivo é desenvolver um sistema baseado em Redes Neurais Convolucionais (CNNs) para a inspeção automatizada de qualidade em produtos industriais. A justificativa para essa abordagem está na crescente demanda por processos de garantia de qualidade precisos e eficientes no setor industrial. Nossa metodologia envolve a coleta de imagens de produtos, pré-processamento dos dados, treinamento de um modelo CNN e avaliação de sua precisão na identificação de defeitos. O cronograma detalhado inclui etapas como preparação de dados, implementação do modelo e elaboração do relatório final. As referências utilizadas incluem trabalhos sobre visão computacional, redes neurais convolucionais e inspeção de qualidade automatizada.

**Index Terms**—inteligência artificial, Redes Neurais Convolucionais (CNN), classificador, processamento de imagem.

## I. OBJETIVOS

Neste projeto, nosso foco principal é explorar a aplicação de Redes Neurais Convolucionais (CNNs) na inspeção automatizada de qualidade de produtos industriais. Para atingir esse objetivo, delineamos as seguintes etapas: Primeiramente, investigaremos detalhadamente o funcionamento e os princípios subjacentes às Redes Neurais Convolucionais quando aplicadas à tarefa específica de detecção e classificação de defeitos visuais em produtos. Buscaremos compreender como as CNNs utilizam camadas convolucionais para extrair características relevantes, como texturas, padrões e anomalias, em imagens capturadas de produtos industriais.

Em seguida, realizaremos o pré-processamento das imagens coletadas de datasets industriais, como o MVTec AD, ajustando-as para condições consistentes de tamanho, iluminação e contraste. Posteriormente, treinaremos as CNNs utilizando essas imagens processadas, explorando diferentes arquiteturas de redes, como ResNet e MobileNet, para maximizar a capacidade de generalização do modelo. Durante essa etapa, implementaremos técnicas de aumento de dados (data augmentation) para melhorar a robustez do sistema frente a variações nos produtos e condições operacionais.

Avaliaremos a eficácia das Redes Neurais Convolucionais na detecção e classificação de defeitos em produtos industriais. Utilizaremos métricas de desempenho, como acurácia, precisão, recall e F1-score, para medir a qualidade das previsões obtidas pelo modelo. Essa avaliação nos permitirá com-

preender a adequação das CNNs para aplicação em cenários industriais reais.

Finalmente, analisaremos os resultados obtidos após a aplicação do modelo. Nosso objetivo é identificar padrões de defeitos e tendências recorrentes nos produtos analisados, proporcionando insights relevantes que poderão contribuir para a melhoria dos processos de produção e controle de qualidade. Essa análise reforçará a viabilidade do uso de CNNs na automação da inspeção de qualidade em ambientes industriais.

## II. JUSTIFICATIVA

A inspeção de qualidade é uma etapa crítica nos processos industriais, mas métodos tradicionais, como a inspeção manual, são suscetíveis a erros, demorados e custosos, especialmente em ambientes de produção em larga escala. Com o avanço da Indústria 4.0, a automação e a adoção de tecnologias baseadas em inteligência artificial se tornaram essenciais para atender às crescentes demandas por eficiência e precisão. Redes Neurais Convolucionais (CNNs) demonstraram alto desempenho em tarefas de análise de imagens, tornando-se uma solução promissora para a detecção e classificação de defeitos visuais em produtos industriais. Este projeto justifica-se pela capacidade de CNNs de reduzir significativamente o tempo e os custos de inspeção, ao mesmo tempo que melhora a consistência e a confiabilidade do controle de qualidade.

## III. METODOLOGIA

Nesta seção, descreveremos os passos metodológicos adotados para o desenvolvimento de um sistema de inspeção automatizada de qualidade em produtos industriais utilizando Redes Neurais Convolucionais (CNNs). Desde a preparação dos dados até a avaliação do desempenho do modelo, apresentaremos cada etapa de forma detalhada e sistemática.

### A. Coleta de Dados

A etapa inicial consiste na seleção e coleta de imagens de produtos industriais, abrangendo itens com e sem defeitos visuais. Para isso, utilizaremos datasets disponíveis publicamente, como o MVTec AD, que oferece uma ampla variedade de categorias de produtos e tipos de defeitos, incluindo arranhões, rachaduras e falhas estruturais. Essa base de dados será fundamental para treinar e avaliar nosso modelo, garantindo uma amostra diversificada e representativa das condições reais encontradas na indústria.

### B. Pré-processamento de Dados

O pré-processamento das imagens é uma etapa crucial para preparar os dados antes de serem aplicados ao modelo de aprendizado profundo. As seguintes etapas serão realizadas:

- **Redimensionamento:** Ajustaremos todas as imagens para dimensões padronizadas, compatíveis com a entrada da rede neural convolucional.
- **Normalização:** Converteremos os valores dos pixels para a faixa  $[0, 1]$ , a fim de melhorar a convergência do modelo durante o treinamento.
- **Data Augmentation:** Aplicaremos técnicas de aumento de dados, como rotações, espelhamentos e ajustes de brilho, para ampliar a diversidade do dataset e melhorar a robustez do modelo.
- **Remoção de Ruídos:** Utilizaremos filtros para suavizar as imagens e minimizar artefatos que possam impactar a análise.

### C. Treinamento do Modelo

O modelo será desenvolvido utilizando Redes Neurais Convolucionais (CNNs), com base em arquiteturas pré-treinadas, como ResNet, VGG ou MobileNet, ajustadas para a tarefa de detecção de defeitos. O treinamento será realizado utilizando a biblioteca TensorFlow ou PyTorch, que permitirá maior flexibilidade no ajuste dos hiperparâmetros.

Durante essa etapa, o modelo aprenderá a identificar padrões e características relevantes nas imagens, como texturas, bordas e anomalias. Dividiremos o dataset em conjuntos de treinamento, validação e teste, para avaliar a generalização do modelo em dados não vistos anteriormente.




Fig. 1. Estrutura de uma Rede Neural Convolucional

### D. Avaliação do Modelo

Para avaliar o desempenho do modelo na detecção e classificação de defeitos, utilizaremos métricas como:

- **Acurácia:** Mede a proporção de previsões corretas em relação ao total.
- **Precisão:** Avalia a proporção de defeitos corretamente identificados em relação ao total de predições como defeitos.
- **Recall:** Mede a proporção de defeitos reais identificados pelo modelo.
- **F1-Score:** Combina precisão e recall, oferecendo uma métrica balanceada.

Além disso, analisaremos a matriz de confusão para entender melhor os erros do modelo, diferenciando falsos positivos e falsos negativos. Esse processo nos permitirá identificar possíveis melhorias para ajustes futuros.

### E. Análise dos Resultados

Com base nos resultados obtidos, analisaremos os padrões e tendências nos tipos de defeitos detectados. O objetivo é avaliar a eficácia do sistema em diferentes cenários e propor melhorias para sua aplicação em ambiente industrial. Por fim, discutiremos a escalabilidade do modelo e sua integração em linhas de produção reais, destacando seu potencial impacto na eficiência operacional e na redução de custos.

## IV. RESULTADOS ESPERADOS

A inspeção automatizada de qualidade em produtos industriais desempenha um papel crucial na modernização e eficiência dos processos de produção, especialmente em ambientes que demandam alto controle de qualidade. Neste projeto, exploramos a aplicação de Redes Neurais Convolucionais (CNNs) para identificar e classificar defeitos visuais em produtos, contribuindo para a automação do controle de qualidade e a redução de custos operacionais.

Ao término deste projeto, esperamos que as CNNs demonstrem um desempenho significativo na detecção de defeitos, com alta acurácia e eficiência em diferentes tipos de produtos e condições de produção. As redes convolucionais devem ser capazes de identificar padrões complexos em imagens, como arranhões, deformações e manchas, destacando sua capacidade de generalização para múltiplos cenários industriais. A utilização de arquiteturas como ResNet ou MobileNet deve permitir o balanceamento entre precisão e velocidade, tornando o sistema adequado para aplicações em tempo real na linha de produção.

Reconhecemos que a qualidade dos dados de treinamento e a presença de ruídos nas imagens podem influenciar os resultados. No entanto, ao aplicar técnicas robustas de pré-processamento e aumento de dados, pretendemos mitigar esses desafios e melhorar a consistência do modelo. Além disso, embora as CNNs apresentem alta capacidade de detecção, casos mais sutis de defeitos podem exigir ajustes adicionais no modelo ou na coleta de dados.

As aplicações práticas desse projeto são vastas. Espera-se que o sistema seja escalável e aplicável a diferentes setores industriais, como manufatura, alimentos, farmacêutica e eletrônicos. Empresas poderão utilizá-lo para otimizar seus processos de controle de qualidade, reduzindo desperdícios e aumentando a satisfação do cliente. Em suma, acreditamos que a inspeção de qualidade automatizada utilizando CNNs pode ser uma ferramenta poderosa para a Indústria 4.0, promovendo a eficiência e a sustentabilidade dos processos industriais.

## V. CRONOGRAMA

O cronograma detalhado do projeto foi cuidadosamente planejado para garantir o cumprimento das atividades dentro dos prazos estabelecidos. As principais etapas e datas incluem:

TABLE I  
CRONOGRAMA DE ATIVIDADES.

Data	Atividades
21/01/2025	Seleção do Dataset
21/01/2025	Discussão de Ideias
25/01/2025	Escrita da Proposta
27/01/2025	Entrega da Proposta
27/01/2025 à 03/03/2025	Desenvolvimento do Projeto
05/03/2025	Finalização do Projeto
05/03/25 à 05/03/25	Escrita do Relatório
10/03/25 à 11/03/25	Elaboração dos Slides
12/03/25	Checklist do Projeto
17/03/25	Entrega do Projeto

## REFERENCES

- [1] Lecun, Y., Bottou, L., Bengio, Y., Haffner, P. (1998). "Gradient-based learning applied to document recognition." *Proceedings of the IEEE*, 86(11), 2278-2324.
- [2] Paul Bergmann, Michael Fauser, David Sattlegger, and Carsten Steger, "A Comprehensive Real-World Dataset for Unsupervised Anomaly Detection", *IEEE Conference on Computer Vision and Pattern Recognition*, 2019
- [3] MVTec Software GmbH, "MVTec Anomaly Detection Dataset Downloads," MVTec. [Online]. Disponível em: <https://www.mvtec.com/company/research/datasets/mvtec-ad/downloads>. [Acessado: 15 jan. 2025].
- [4] K. He, X. Zhang, S. Ren, and J. Sun, "Deep Residual Learning for Image Recognition," *arXiv preprint arXiv:1512.03385*, 2015. [Online]. Available: <https://arxiv.org/abs/1512.03385>.
- [5] K. Simonyan and A. Zisserman, "Very Deep Convolutional Networks for Large-Scale Image Recognition," *arXiv preprint arXiv:1409.1556*, 2014. [Online]. Available: <https://arxiv.org/abs/1409.1556>.
- [6] A. G. Howard et al., "MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications," *arXiv preprint arXiv:1704.04861*, 2017. [Online]. Available: <https://arxiv.org/abs/1704.04861>.